

# Két generatív modell

## A Variational Autoencoder és a GAN

Csiszárík Adrián

ELTE TTK Deep Learning Szeminárium, 2018

# Felügyelt tanulás vs. felügyelet nélküli tanulás

## Felügyelt tanulás (Supervised learning)

Adat:  $\{(x_i, y_i)\}_{i=1}^N$

Cél: Megtanulni egy  $f : X \mapsto Y$  leképezést, amely illeszkedik az adatra (és jól általánosít).

Példák: Klasszifikáció, regresszió, szemantikus szegmentáció, objektum detektálás.

# Felügyelt tanulás vs. felügyelet nélküli tanulás

## Felügyelt tanulás (Supervised learning)

Adat:  $\{(x_i, y_i)\}_{i=1}^N$

Cél: Megtanulni egy  $f : X \mapsto Y$  leképezést, amely illeszkedik az adatra (és jól általánosít).

Példák: Klasszifikáció, regresszió, szemantikus szegmentáció, objektum detektálás.

## Felügyelet nélküli tanulás (Unsupervised learning)

Adat:  $\{(x_i)\}_{i=1}^N$ , nincs  $y$ .

Cél: Modellezni a  $p(x)$  eloszlást, megtanulni az adathalmazban lévő rejtett struktúrát.

Példák: Klaszterezés, dimenzióredukció, generatív modellek.

# Felügyelt tanulás vs. felügyelet nélküli tanulás

## Felügyelt tanulás (Supervised learning)

Adat:  $\{(x_i, y_i)\}_{i=1}^N$

Cél: Megtanulni egy  $f : X \mapsto Y$  leképezést, amely illeszkedik az adatra (és jól általánosít).

Példák: Klasszifikáció, regresszió, szemantikus szegmentáció, objektum detektálás.

A felügyelt tanulási módszerek ma már hatékonyan működnek számos modellezési feladatban.  
(Neuronhálók: Narrow AI.)

## Felügyelet nélküli tanulás (Unsupervised learning)

Adat:  $\{(x_i)\}_{i=1}^N$ , nincs  $y$ .

Cél: Modellezni a  $p(x)$  eloszlást, megtanulni az adathalmazban lévő rejtett struktúrát.

Példák: Klaszterezés, dimenzióredukció, generatív modellek.

Nagyon jó lenne, erősen kutatott terület.  
(Neuronhálók: úton a General vagy strong AI felé.)

# Felügyelt tanulás vs. felügyelet nélküli tanulás

## Felügyelt tanulás (Supervised learning)

Adat:  $\{(x_i, y_i)\}_{i=1}^N$

Cél: Megtanulni egy  $f : X \mapsto Y$  leképezést, amely illeszkedik az adatra (és jól általánosít).

Példák: Klasszifikáció, regresszió, szemantikus szegmentáció, objektum detektálás.

A felügyelt tanulási módszerek ma már hatékonyan működnek számos modellezési feladatban.  
(Neuronhálók: Narrow AI.)

## Felügyelet nélküli tanulás (Unsupervised learning)

Adat:  $\{(x_i)\}_{i=1}^N$ , nincs  $y$ .

Cél: Modellezni a  $p(x)$  eloszlást, megtanulni az adathalmazban lévő rejtett struktúrát.

Példák: Klaszterezés, dimenzióredukció, generatív modellek.

Nagyon jó lenne, erősen kutatott terület.  
(Neuronhálók: úton a General vagy strong AI felé.)

# Felügyelet nélküli tanulás (Unsupervised learning)

$$p(x)$$



Ha  $p(x)$  van, minden van.

(Akár  $p(x, y)$  is, valamelyen  $y$  címkekre.)

(Persze ahhoz, hogy használjuk, ezt ki kell faktorálnunk.)

(Viszont vélhetően kevesebb szupervíziós jellel meg tudjuk ezt tenni.)

# Felügyelt tanulás vs. felügyelet nélküli tanulás

Még több motiváció:

- ▶ Nincs minden becímkézve, és rengeteg címkézetlen adat van.
- ▶ Gazdagabb reprezentációs struktúra jön (jöhet!) létre, ha nem csak a feladat szempontjából kapja a szupervíziós jelet a tanulás során a modell.

Konkrét feladatok:

- ▶ Density estimation.
- ▶ Outlier detection.
- ▶ Semi-supervised learning.
- ▶ Unsupervised pre-training.
- ▶ Generatív modellek.

# Generatív modellek

Feladat: Adott  $\{x_1, \dots, x_N\}$  minta valamelyen  $p(x)$  eloszlásból.  
Generálunk elemeket  $p(x)$  eloszlás szerint.

# Generatív modellek

Feladat: Adott  $\{x_1, \dots, x_N\}$  minta valamelyen  $p(x)$  eloszlásból.  
Generálunk elemeket  $p(x)$  eloszlás szerint.

Egy természetes megközelítés:

**Legnagyobb valószínűség módszer:** a parametrikus modellünk  $\theta$  paramétereit hangoljuk úgy, hogy a mintánknak (tanítópontoknak) minél nagyobb legyen a valószínűsége.

$$\theta^* = \operatorname{argmax}_{\theta} \log p_{\theta}(x_1, x_2, \dots, x_n) = \sum_{i=1}^N \log p_{\theta}(x_i)$$

# Generatív modellek

Feladat: Adott  $\{x_1, \dots, x_N\}$  minta valamelyen  $p(x)$  eloszlásból.  
Generálunk elemeket  $p(x)$  eloszlás szerint.

Egy természetes megközelítés:

**Legnagyobb valószínűség módszer:** a parametrikus modellünk  $\theta$  paramétereit hangoljuk úgy, hogy a mintánknak (tanítópontoknak) minél nagyobb legyen a valószínűsége.

$$\theta^* = \operatorname{argmax}_{\theta} \log p_{\theta}(x_1, x_2, \dots, x_n) = \sum_{i=1}^N \log p_{\theta}(x_i)$$

Elvárás: persze itt is szeretnénk, ha általánosítana a modellünk, azaz nem csak a bemagolt tanítópontokat adná vissza.

Mire jó?

- ▶ Szimulációk a megtanult  $p_{\theta}(x)$  segítségével.
- ▶ Példák generálása tanulási feladatokhoz.
- ▶ Density estimation, ha meg tudjuk kérdezni a modelltől, hogy mennyi  $p(x)$ .

# Rejtett változós valószínűségi modell

## Rejtett változós valószínűségi modell

Feltételezzük, hogy az  $\{x_i\}_{i=1}^N$  tanítópontok egy rejtett (látens)  $z$  reprezentáció alapján vannak generálva.

A  $p(x, z)$  együttes eloszlást tekintjük  
a látens változók  $z$  vektorával.

# Rejtett változós valószínűségi modell

## Rejtett változós valószínűségi modell

Feltételezzük, hogy az  $\{x_i\}_{i=1}^N$  tanítópontok egy rejtett (látens)  $z$  reprezentáció alapján vannak generálva.

A  $p(x, z)$  együttes eloszlást tekintjük  
a látens változók  $z$  vektorával.

A Variational Autoencoder és a GAN esetében is

a  $z$  explicit megjelenik.

# Rejtett változós valószínűségi modell

## Rejtett változós valószínűségi modell

Feltételezzük, hogy az  $\{x_i\}_{i=1}^N$  tanítópontok egy rejtett (látens)  $z$  reprezentáció alapján vannak generálva.

A  $p(x, z)$  együttes eloszlást tekintjük  
a látens változók  $z$  vektorával.

A Variational Autoencoder és a GAN esetében is

a  $z$  explicit megjelenik.

$p(x)$ -ből nehéz mintavételezni, ez az a bonyolult eloszlás amit modellezni akarunk.

$p(z)$ : feltételezünk valamilyen számunkra elérhető eloszlást, amiből tudunk mintavételezni. Például:  $p(z) \sim \mathcal{N}(0, I)$ .

Csinálunk  $z$ -kből  $x$ -eket egy neuronhálóval.

# Rejtett változós valószínűségi modell

## Rejtett változós valószínűségi modell

Feltételezzük, hogy az  $\{x_i\}_{i=1}^N$  tanítópontok egy rejtett (látens)  $z$  reprezentáció alapján vannak generálva.

A  $p(x, z)$  együttes eloszlást tekintjük  
a látens változók  $z$  vektorával.

A Variational Autoencoder és a GAN esetében is

a  $z$  explicit megjelenik.

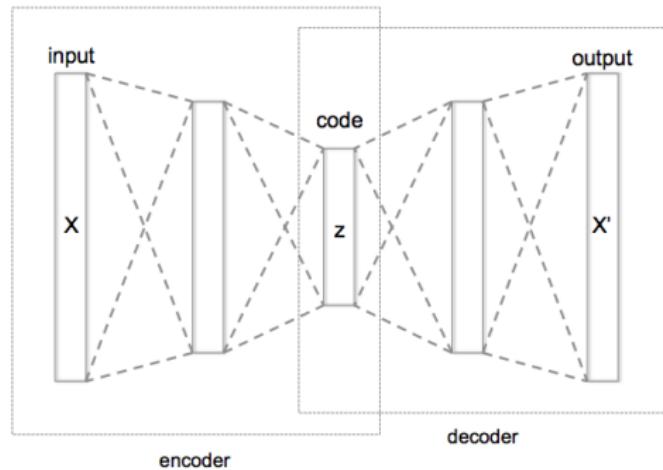
$p(x)$ -ből nehéz mintavételezni, ez az a bonyolult eloszlás amit modellezni akarunk.

$p(z)$ : feltételezünk valamilyen számunkra elérhető eloszlást, amiből tudunk mintavételezni. Például:  $p(z) \sim \mathcal{N}(0, I)$ .

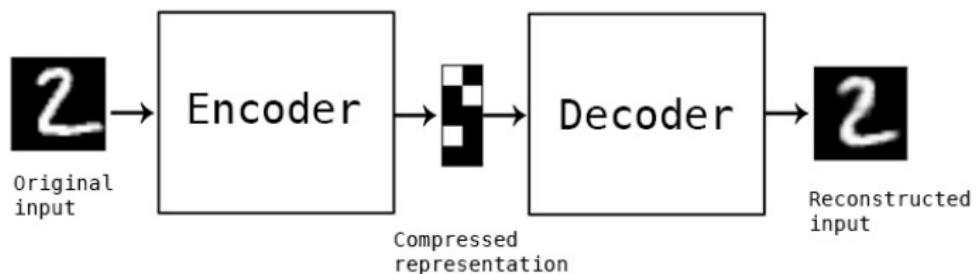
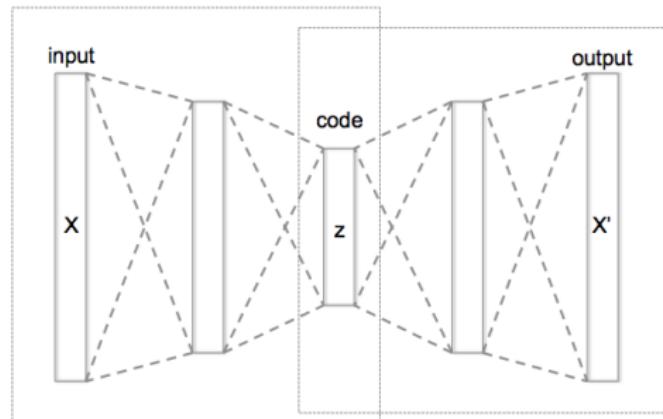
Csinálunk  $z$ -kből  $x$ -eket egy **neuronhálóval**. Wow.

$$f_{\theta}(z) = x$$

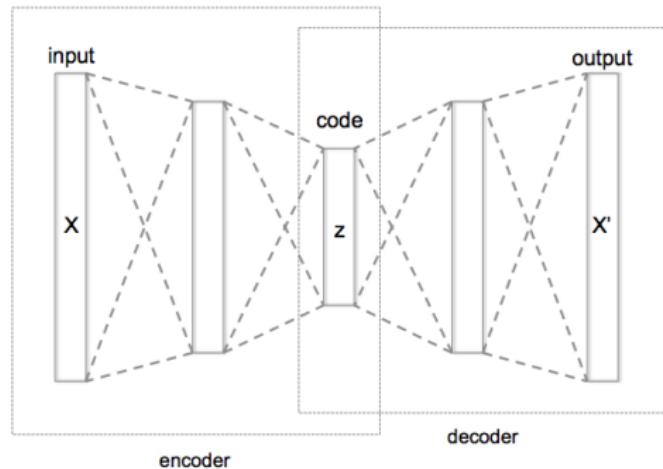
# Az autoencoder struktúra



# Az autoencoder struktúra



# Az autoencoder struktúra

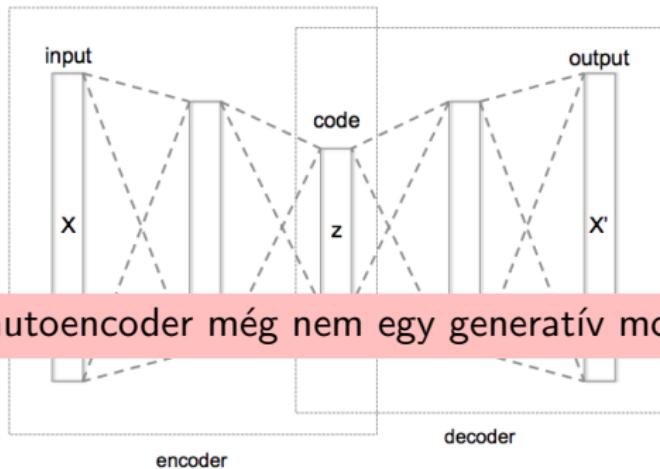


Nemlinearitások nélkül: kapcsolat PCA-val

Variációk, különböző megszorításokkal:

- ▶ Sparse autoencoder (szűkületben  $l_0$  vagy  $l_1$  sparsitás)
- ▶ Denoising autoencoder
- ▶ Variational Autoencoder

# Az autoencoder struktúra



Az autoencoder még nem egy generatív modell.

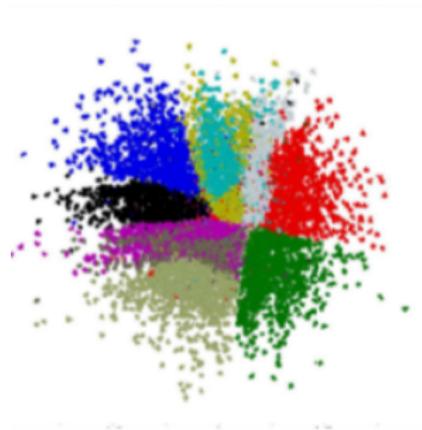
Nemlinearitások nélkül: kapcsolat PCA-val

Variációk, különböző megszorításokkal:

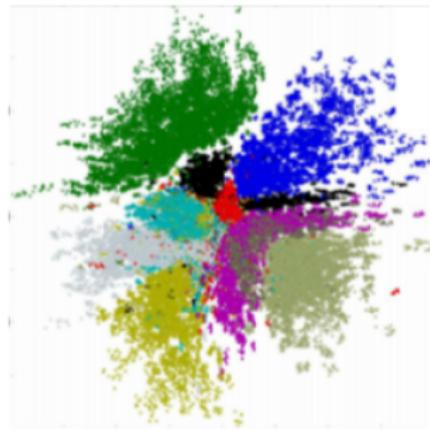
- ▶ Sparse autoencoder (szűkületben  $l_0$  vagy  $l_1$  sparsitás)
- ▶ Denoising autoencoder
- ▶ Variational Autoencoder

## Látens tér struktúra mintavételezéshez

Jó



Nem jó



# A Variational Autoencoder

A tanítás a  $\log p_\theta(x)$  maximalizálásával történik a tanítóhalmazon.

A  $z$  látens teret formáljuk normálissá:  $p(z) \sim \mathcal{N}(0, I)$  prior.

A látens változós modellben:

$$\log p_\theta(x) = \log \int p_\theta(x, z) dz$$

# A Variational Autoencoder

A tanítás a  $\log p_\theta(x)$  maximalizálásával történik a tanítóhalmazon.

A  $z$  látens teret formáljuk normálissá:  $p(z) \sim \mathcal{N}(0, I)$  prior.

A látens változós modellben:

$$\log p_\theta(x) = \log \int p_\theta(x, z) dz$$

Rossz hír: ez intraktabilis.

A legtöbb  $z$ -re viszont a  $p_\theta(x|z)$  tipikusan nulla vagy  $\ll \epsilon$ .

# A Variational Autoencoder

A tanítás a  $\log p_\theta(x)$  maximalizálásával történik a tanítóhalmazon.

A  $z$  látens teret formáljuk normálissá:  $p(z) \sim \mathcal{N}(0, I)$  prior.

A látens változós modellben:

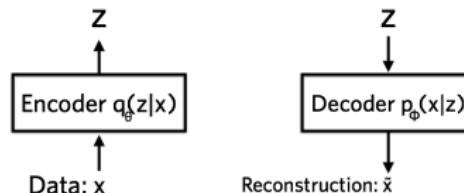
$$\log p_\theta(x) = \log \int p_\theta(x, z) dz$$

Rossz hír: ez intraktabilis.

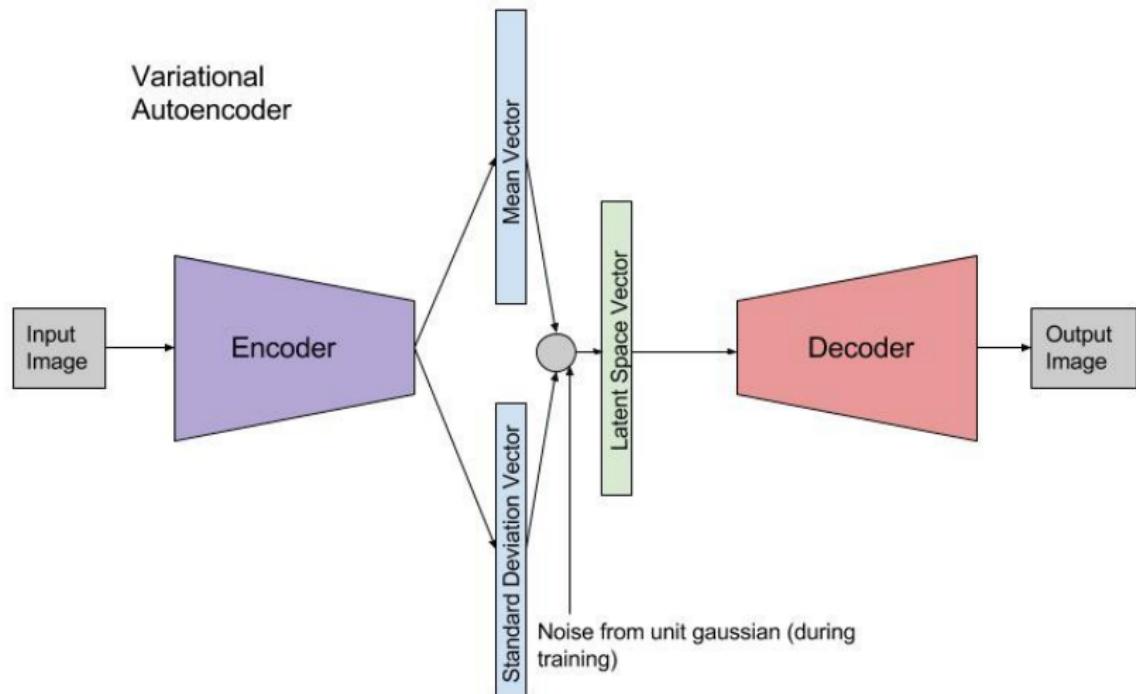
A legtöbb  $z$ -re viszont a  $p_\theta(x|z)$  tipikusan nulla vagy  $\ll \epsilon$ .

A Variational Autoencoder két komponensből áll:

- ▶ Decoder:  $p_\theta(x|z)$ , ennek segítségével modellezhetjük a  $p(x|z)$  eloszlást, a likelihoodot.
- ▶ Encoder:  $q_\phi(z|x)$ , ennek segítségével modellezhetjük a  $p_\theta(z|x)$  eloszlást, a posteriort.



# VAE



# Az Evidence Lower BOund (ELBO)

$$\begin{aligned}\log p_{\theta}(x_i) &= \mathbb{E}_{z \sim q_{\phi}(z|x_i)} [\log p_{\theta}(x_i)] \\&= \mathbb{E}_z [\log \frac{p_{\theta}(x_i|z)p_{\theta}(z)}{p_{\theta}(z|x_i)}] \text{ (Bayes)} \\&= \mathbb{E}_z [\log \frac{p_{\theta}(x_i|z)p_{\theta}(z)}{p_{\theta}(z|x_i)} \frac{q_{\phi}(z|x_i)}{q_{\phi}(z|x_i)}] \text{ (Szorozva 1-el)} \\&= \mathbb{E}_z [\log p_{\theta}(x_i|z)] - \mathbb{E}_z [\log \frac{q_{\phi}(z|x_i)}{p_{\theta}(z)}] + \mathbb{E}_z [\log \frac{q_{\phi}(z|x_i)}{p_{\theta}(z|x_i)}] \\&= \underbrace{\mathbb{E}_z [\log p_{\theta}(x_i|z)]}_{\text{rekonstrukciós hiba, mintavételezésel tudjuk közelíteni (reparam. trick)}} - \underbrace{\mathbb{E}_z [\log \frac{q_{\phi}(z|x_i)}{p_{\theta}(z)}]}_{\text{A posteriort a priorba húzó erő. Ha } p(z) \text{ normális, van zárt alakja.}} + \underbrace{\mathbb{E}_z [\log \frac{q_{\phi}(z|x_i)}{p_{\theta}(z|x_i)}]}_{\text{Még mindig nehéz, viszont } \geq 0, \text{ dobjuk el, és akkor van egy alsó becslésünk, így kapjuk az ELBO-t}}\end{aligned}$$

<sup>1</sup>Diederik P Kingma, Max Welling: "Auto-Encoding Variational Bayes", ICLR 2014 <https://arxiv.org/abs/1312.6114>

# Az Evidence Lower BOund (ELBO)

$$\log p_{\theta}(x_i) = \mathbb{E}_{z \sim q_{\phi}(z|x_i)} [\log p_{\theta}(x_i)]$$

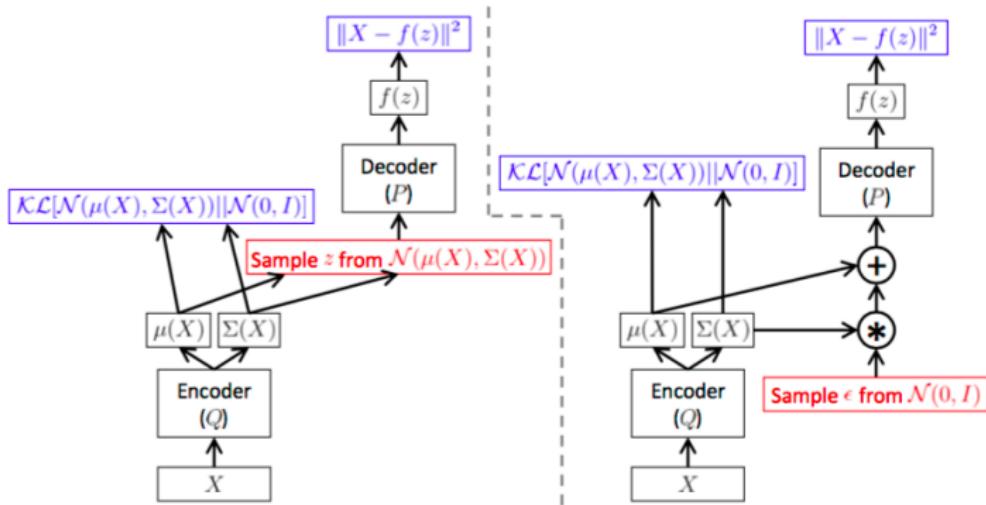
$$= \mathbb{E}_{z \sim q_{\phi}(z|x_i)} [p_{\theta}(x_i|z)p_{\theta}(z)] \quad (\text{Bayes})$$

```
49 # instantiate VAE model
50 vae = Model(x, x_decoded_mean)
51
52 # Compute VAE loss
53 xent_loss = original_dim * metrics.binary_crossentropy(x, x_decoded_mean)
54 kl_loss = - 0.5 * K.sum(1 + z_log_var - K.square(z_mean) - K.exp(z_log_var), axis=-1)
55 vae_loss = K.mean(xent_loss + kl_loss)
```

$$= \underbrace{\mathbb{E}_z [\log p_{\theta}(x_i|z)]}_{\text{rekonstrukciós hiba, mintavételezésel tudjuk közelíteni (reparam. trick)}} - \underbrace{\text{KL}(q_{\phi}(z|x_i) \parallel p_{\theta}(z))}_{\text{A posteriort a priorba húzó erő. Ha } p(z) \text{ normális, van zárt alakja.}} + \underbrace{\text{KL}(q_{\phi}(z|x_i) \parallel p_{\theta}(z|x_i))}_{\text{Még mindig nehéz, viszont } \geq 0, \text{ dobjuk el, és akkor van egy alsó becslésünk, így kapjuk az ELBO-t}}$$

<sup>1</sup>Diederik P Kingma, Max Welling: "Auto-Encoding Variational Bayes", ICLR 2014 <https://arxiv.org/abs/1312.6114>

# VAE - Reparametrization Trick



# Az ELBO különböző alakjai

## Az ELBO

$$\begin{aligned}\log p_\theta(x) &= \log \int p_\theta(x, z) dz = \log \int q_\theta(z|x) \frac{p_\theta(x, z)}{q_\theta(z|x)} dz \\ &= \log \mathbb{E}_{q_\theta(z|x)} \frac{p_\theta(x, z)}{q_\theta(z|x)} \geq \mathbb{E}_{q_\theta(z|x)} \log \frac{p_\theta(x, z)}{q_\theta(z|x)} = ELBO\end{aligned}$$

## Átlagos negatív energia + $\mathbb{H}(q_\theta(z|x))$ alak

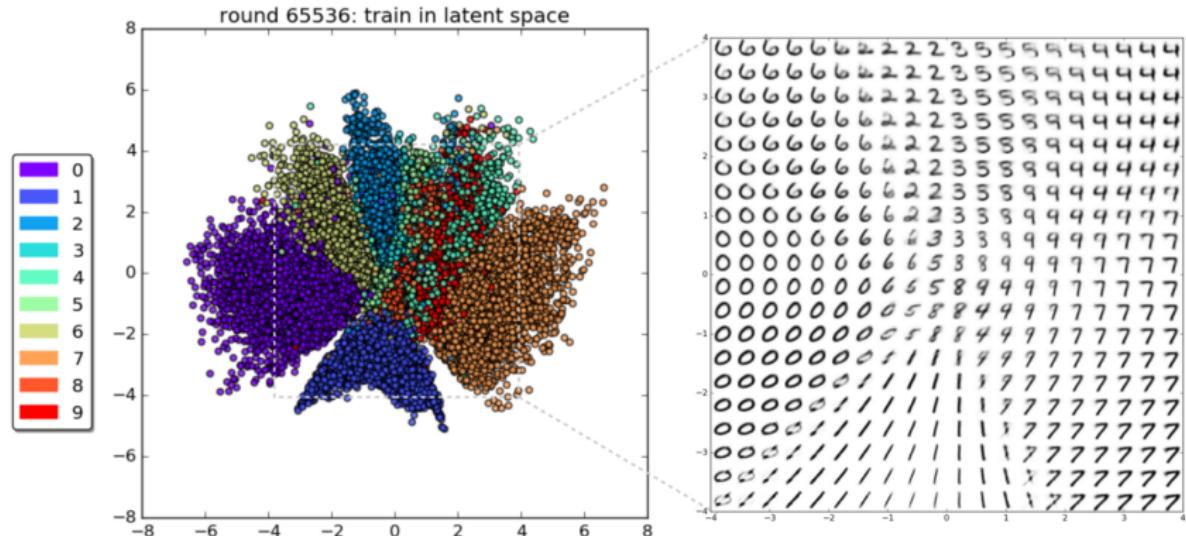
$$\begin{aligned}ELBO &= \mathbb{E}_{q_\theta(z|x)} \log \frac{p_\theta(x, z)}{q_\theta(z|x)} = \mathbb{E}_{q_\theta(z|x)} \log p_\theta(x, z) - \mathbb{E}_{q_\theta(z|x)} \log q_\theta(z|x) \\ &= \underbrace{\mathbb{E}_{q_\theta(z|x)} \log(p_\theta(x|z)p_\theta(z))}_{p_\theta(z) \text{ legyen nagy ott, ahol jól rekonstruál}} - \underbrace{\int q_\theta(z|x) \log q_\theta(z|x) dz}_{\mathbb{H}(q_\theta(z|x))}\end{aligned}$$

# Az ELBO különböző alakjai

Pontonkénti rekonstrukció –  $q_\theta(z_i|x_i)$  priorhoz húzása

$$\begin{aligned}ELBO &= \mathbb{E}_{q_\theta(z|x)} \log \frac{p_\theta(x, z)}{q_\theta(z|x)} \\&= \frac{1}{N} \sum_{i=1}^N \mathbb{E}_{q_\theta(z_i|x_i)} [\log p(x_i, z_i)] - \text{KL}(q_\theta(x_i|z_i) \parallel p(z_i))\end{aligned}$$

# Látens tér a Variational Autoencoderben



- ▶ Aritmetika a látens térben
  - ▶ Diagonális prior  $p(z)$ -n, dekorrálált látens jellemzők
  - ▶ Van inferencia modellünk:  $q_\theta(z|x)$
  - ▶ Van likelihood modellünk  $p_\phi(x|z)$  segítségével
  - ▶ Előrelépés: komplexebb, jobban illeszkedő priorok, jobb inferencia modell mint a dekorrelált Gaussian

## VAE példa program

[https://github.com/keras-team/keras/blob/master/examples/variational\\_autoencoder.py](https://github.com/keras-team/keras/blob/master/examples/variational_autoencoder.py)

# GAN

# Generatív modellek

Feladat: Adott  $\{x_1, \dots, x_N\}$  minta valamelyen  $p(x)$  eloszlásból.  
Generálunk elemeket  $p(x)$  eloszlás szerint.

# Generatív modellek

Feladat: Adott  $\{x_1, \dots, x_N\}$  minta valamelyen  $p(x)$  eloszlásból.  
Generálunk elemeket  $p(x)$  eloszlás szerint.

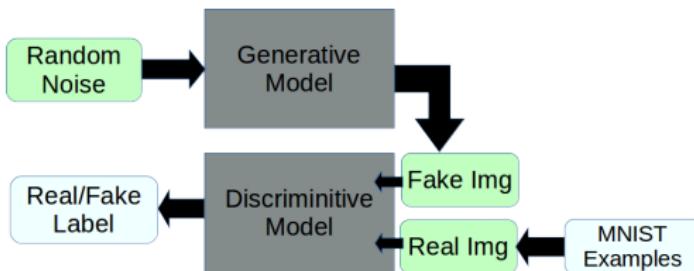
Engedjük el, hogy legyen explicit sűrűség modellünk. Csak generálni akarunk.

# Generatív modellek

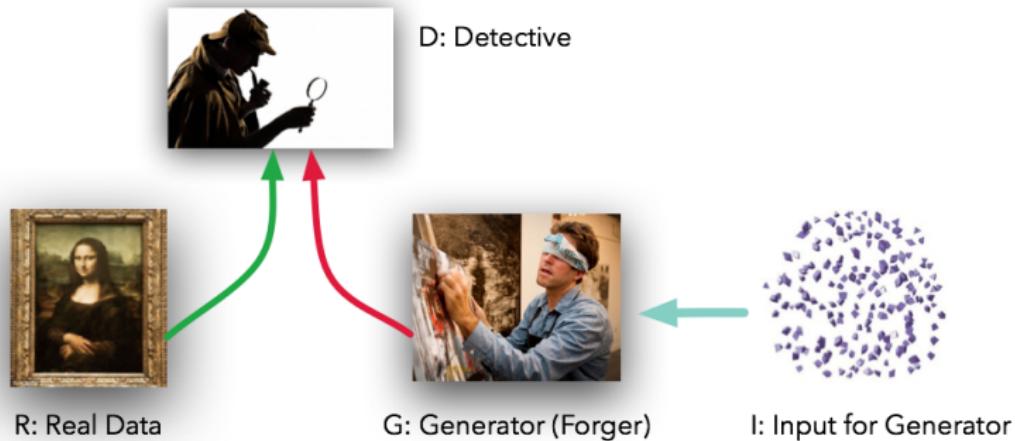
Feladat: Adott  $\{x_1, \dots, x_N\}$  minta valamelyen  $p(x)$  eloszlásból.  
Generálunk elemeket  $p(x)$  eloszlás szerint.

Engedjük el, hogy legyen explicit sűrűség modellünk. Csak generálni akarunk.

- ▶ Rejtett változós modell  $z \mapsto x$
- ▶ Játékelméleti megközelítés: két játékos (modell) játszik egymás ellen.
  - ▶ Generátor hálózat: próbálja átverni a diszkriminátor hálózatot úgy, hogy minél realisztikusabb képeket generál
  - ▶ Diszkriminátor hálózat: próbálja megkülönböztetni a hamis képeket a valós képektől.



# GAN modell



# GAN optimalizálás

Minimax célfüggvény:

$$\min_{\theta_g} \max_{\theta_d} [\mathbb{E}_{x \sim p_{data}} \log D_{\theta_d}(x) + \mathbb{E}_{z \sim p(z)} \log(1 - D_{\theta_d}(G_{\theta_g}(z)))]$$

Tanítás: alternáljuk a következőket

- ▶ Gradiens emelkedés a diszkriminátoron

$$\max_{\theta_d} [\mathbb{E}_{x \sim p_{data}} \log D_{\theta_d}(x) + \mathbb{E}_{z \sim p(z)} \log(1 - D_{\theta_d}(G_{\theta_g}(z)))]$$

- ▶ Gradiens eredszkedés a generátoron

$$\min_{\theta_g} \mathbb{E}_{z \sim p(z)} \log(1 - D_{\theta_d}(G_{\theta_g}(z)))$$

# GAN optimalizálás

Minimax célfüggvény:

$$\min_{\theta_g} \max_{\theta_d} [\mathbb{E}_{x \sim p_{data}} \log D_{\theta_d}(x) + \mathbb{E}_{z \sim p(z)} \log(1 - D_{\theta_d}(G_{\theta_g}(z)))]$$

Tanítás: alternáljuk a következőket

- ▶ Gradiens emelkedés a diszkriminátoron

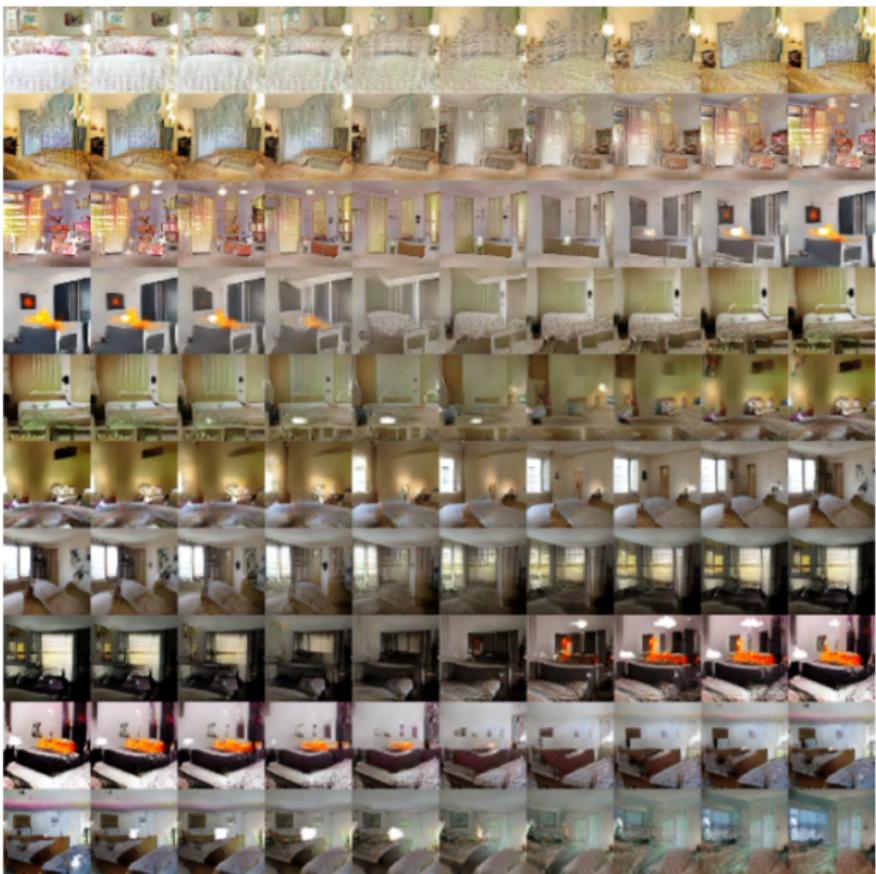
$$\max_{\theta_d} [\mathbb{E}_{x \sim p_{data}} \log D_{\theta_d}(x) + \mathbb{E}_{z \sim p(z)} \log(1 - D_{\theta_d}(G_{\theta_g}(z)))]$$

- ▶ Gradiens eredszkedés a generátoron

$$\min_{\theta_g} \mathbb{E}_{z \sim p(z)} \log(1 - D_{\theta_d}(G_{\theta_g}(z)))$$

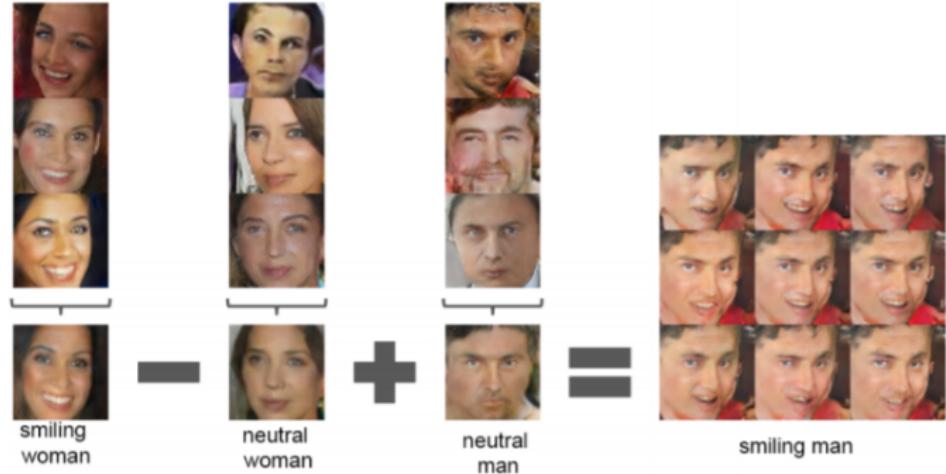
- ▶ Gradiens eredszkedés a generátoron (másik változat)

$$\max_{\theta_g} \mathbb{E}_{z \sim p(z)} \log D_{\theta_d}(G_{\theta_g}(z))$$

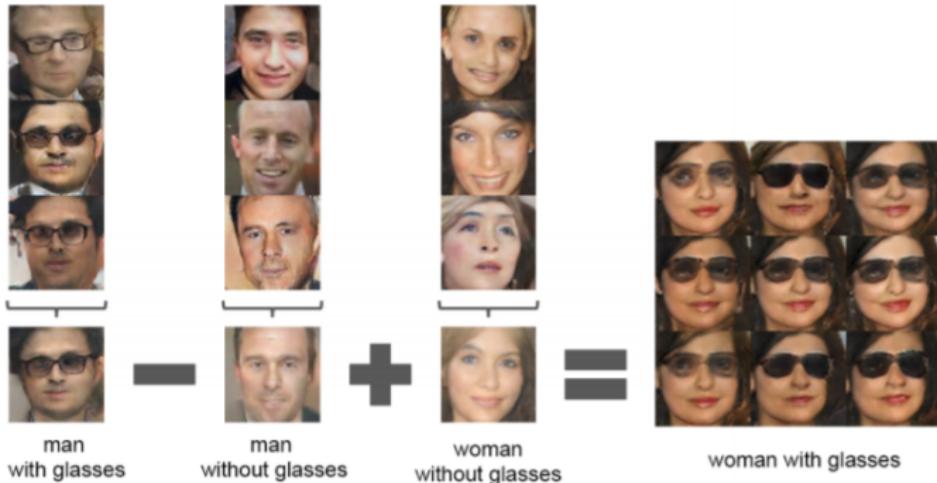


---

<sup>1</sup>Radford et al.: Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks, ICLR 2016



<sup>1</sup>Radford et al.: Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks, ICLR 2016



# The GAN Zoo

<https://github.com/hindupuravinash/the-gan-zoo>

# GAN példa program

<https://github.com/eriklindernoren/Keras-GAN>

# Összefoglalás

- ▶ VAE (Variational Autoencoder)
  - ▶ Van inferencia modell
  - ▶ Van likelihood modell
- ▶ GAN (Generative Adversarial Networks)
  - ▶ Látványos eredmények
  - ▶ Trükkösebb, instabil tanulás
  - ▶ Nincs inferencia modell
  - ▶ Izgalmas konstrukció
  - ▶ The GAN Zoo
- ▶ Variational optimization
- ▶ Adversarial konstrukció úgy általában
- ▶ Nemlineáris PCA
- ▶ Valószínűségeloszlások közötti távolság fogalmak